



به نام خدا
دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر



درس یادگیری ماشین تمرین پنجم

| | |
|--------------------|------------------|
| نام و نام خانوادگی | امیرحسین پورداود |
| شماره دانشجویی | ۸۱۰۱۰۱۱۲۰ |
| تاریخ ارسال گزارش | ۱۴۰۲.۱۱.۰۸ |

فهرست

- پاسخ ۱ - پرسش ۲
- پاسخ ۲ - پرسش ۳
- پاسخ ۳ - پرسش ۴
- ۱-۳. قسمت ۱ ۴
- ۲-۳. قسمت ۲ ۴
- پاسخ ۴ - پرسش ۵
- ۱-۴. قسمت ۱ ۵
- ۲-۴. قسمت ۲ ۵
- پاسخ ۵ - پرسش ۶
- ۱-۵. قسمت ۱ ۶
- ۲-۵. قسمت ۲ ۷
- پاسخ ۶ - شبیه سازی ۸
- ۱-۶. قسمت ۱ ۸
- ۲-۶. قسمت ۲ ۹
- ۳-۶. قسمت ۳ ۱۰
- ۴-۶. قسمت ۴ ۱۱
- پاسخ ۷ - شبیه سازی ۱۲

پاسخ ۱ - پرسش

Q1/

Q2/

$$J_1(w) = \frac{(\mu_1 - \mu_2)^2}{\sigma_1^2 + \sigma_2^2} \Rightarrow w^* = (\Sigma_1 + \Sigma_2)^{-1} (\mu_1 - \mu_2)$$

$$y = w^T x \Rightarrow \begin{cases} \tilde{\mu}_1 = w^T \mu_1 \\ \tilde{\mu}_2 = w^T \mu_2 \end{cases}$$

$$E\{x\} = 0$$

$$\tilde{\xi}_1^2 = \sum_{i=1}^n (w^T x_i) (w^T x_i)^T = w^T \left(\sum_{i=1}^n x_i x_i^T \right) w = w^T \Sigma_1^2 w$$

$$\tilde{\xi}_2^2 = w^T \Sigma_2^2 w$$

$$J_2(w) = \frac{(\tilde{\mu}_1 - \tilde{\mu}_2)^2}{\tilde{\xi}_1^2 + \tilde{\xi}_2^2} = \frac{(w^T \mu_1 - w^T \mu_2)^2}{w^T (\Sigma_1^2 + \Sigma_2^2) w} = \frac{w^T \overbrace{(\mu_1 - \mu_2)(\mu_1 - \mu_2)^T}^{\Sigma_B} w}{w^T \underbrace{(\Sigma_1^2 + \Sigma_2^2)}_{\Sigma_W} w}$$

$$\text{Max}_w \frac{w^T \Sigma_B w}{w^T \Sigma_W w} \equiv \text{Max}_w w^T \Sigma_B w \quad \text{s.t. } w^T \Sigma_W w = K$$

$$\text{Lagrangian} = w^T \Sigma_B w - \lambda (w^T \Sigma_W w - K)$$

$$\nabla_w L = 2 \Sigma_B w - 2 \lambda \Sigma_W w = 0 \Rightarrow \underbrace{\Sigma_W^{-1} \Sigma_B w^*}_{\text{eigenvalue}} = \lambda w^*$$

$$\lambda w = \Sigma_W^{-1} \Sigma_B w \quad \text{که } w \text{ بردار ویژه و مقدار آن با } \Sigma_W^{-1} \Sigma_B \text{ است.}$$

$$\text{چون } a a^T u = \alpha a \rightarrow \lambda w = \Sigma_W^{-1} \cdot \alpha \cdot (\mu_1 - \mu_2)$$

$$\rightarrow w = \frac{\alpha}{\lambda} \Sigma_W^{-1} (\mu_1 - \mu_2) \Rightarrow w^* = (\Sigma_1 + \Sigma_2)^{-1} (\mu_1 - \mu_2) \quad \checkmark$$

پاسخ ۳ - پرسش

۳-۱. قسمت ۱

تحلیل مولفه اصلی (PCA):

- مشکل: داده های با ابعاد بالا می تواند منجر به افزایش پیچیدگی محاسباتی و نیاز به حافظه در هنگام محاسبه ماتریس کوواریانس شود.

- راه حل: از الگوریتم های کارآمد یا تکنیک های کاهش ابعاد مانند PCA تصادفی برای مدیریت مجموعه داده های بزرگ استفاده میتوان استفاده کرد. علاوه بر این، روش های PCA افزایشی را نیز می توان برای داده های آنلاین یا جریانی استفاده کرد.

تحلیل تشخیص خطی (LDA):

- مشکل: مشابه PCA، LDA در فضاهای با ابعاد بالا به دلیل محاسبه ماتریس های پراکندگی با چالش هایی مواجه است.

- راه حل: روش های منظم سازی را می توان برای تثبیت محاسبات ماتریس های پراکندگی به کار برد. همچنین، تکنیک های تجزیه ارزش ویژه را می توان برای مدیریت کارآمدتر سناریوهای با ابعاد بالا بهینه کرد.

۳-۲. قسمت ۲

متریک: اطلاعات متقابل (MI) بین داده و برچسب:

بهبودها:

- MI می تواند وابستگی های غیرخطی بین ویژگی ها و برچسب ها را ثبت کند و آن را برای انواع خاصی از توزیع های داده مناسب تر می کند.
- ممکن است معیار آموزنده تری از رابطه بین متغیرها در مقایسه با ماتریس کوواریانس ارائه دهد.

معایب:

- از نظر محاسباتی نسبت به روش های مبتنی بر کوواریانس سنتی نیازمندتر است.
- حساسیت به انتخاب binning یا گسسته سازی در فرآیند تخمین.

- MI ممکن است به داده های بیشتری برای تخمین دقیق نیاز داشته باشد، به ویژه در فضاهای با ابعاد بالا.

انتخاب متریک به ماهیت داده ها و روابط زیربنایی بین متغیرها بستگی دارد. در حالی که MI ممکن است مزایایی در گرفتن وابستگی های غیر خطی ارائه دهد، با افزایش هزینه های محاسباتی و چالش هایی در تنظیم پارامترها همراه است.

پاسخ ۴ - پرسش

۴-۱. قسمت ۱

$$p(x|z) = \mathcal{N}(x|wz + \mu, \sigma^2 I) \quad p(z) = \mathcal{N}(0, I)$$

$$p(x) = \int p(x, z) dz, \quad p(x) \stackrel{?}{=} \mathcal{N}(x|\mu, ww^T + \sigma^2 I)$$

a)

$$p(x) = \int p(x|z) p(z) dz$$

$$E[z] = 0$$

$$E(x) = E\{wz + \mu + \varepsilon\} = \mu$$

$$\text{cov}(x) = E\{(x - \mu)(x - \mu)^T\} = E\{(wz + \cancel{\mu} - \cancel{\mu} + \varepsilon)(wz + \cancel{\mu} - \cancel{\mu} + \varepsilon)^T\}$$

$$= E\{wz(wz)^T\} + E\{\varepsilon\varepsilon^T\}$$

$$= E\{wzz^T w^T\} + E\{\varepsilon\varepsilon^T\}$$

$$= w \underbrace{E\{zz^T\}}_I w^T + \sigma^2 I = ww^T + \sigma^2 I \quad \checkmark$$

۴-۲. قسمت ۲

b)

$$p(z|x) = \frac{p(x|z)p(z)}{p(x)}$$

پاسخ ۵ - پرسش

۵-۱. قسمت ۱

Q5/

$$C_1 = \{x_1, x_2, x_4\} \quad C_2 = \{x_3, x_5\}$$

a)

$$\mu_i = \frac{1}{n_i} \sum_{x \in C_i} x_i \Rightarrow \mu_1 = \left[\frac{5}{3}, \frac{2}{3} \right] \quad \mu_2 = \left[\frac{13}{4}, 1 \right]$$

$$d_1 = 2,13 \quad ①$$

$$d_1 = 3,4$$

$$d_2 = 1,79 \quad ①$$

$$d_2 = 3,4$$

$$d_3 = 0,68 \quad ①$$

$$d_3 = 2,02$$

$$d_4 = 3,40$$

$$d_4 = 2,02 \quad ②$$

$$d_5 = 3,59$$

$$d_5 = 2,02 \quad ②$$

$$C_1 = \{x_1, x_2, x_3\}$$

$$C_2 = \{x_4, x_5\}$$

$$\Rightarrow \mu_1 = \left[\frac{1}{2}, \frac{2}{3} \right]$$

$$\mu_2 = [5, 1]$$

$$d_1 = 1,42 \quad ①$$

$$d_1 = 5,1$$

$$d = \|x - c_i\|_2$$

$$d_2 = 0,83 \quad ①$$

$$d_2 = 5,1$$

$$d_3 = 1,2 \quad ①$$

$$d_3 = 3,64$$

$$d_4 = 4,55$$

$$d_4 = 1 \quad ②$$

$$d_5 = 4,69$$

$$d_5 = 1 \quad ②$$

با توجه به اینکه داده‌ها تغییر نمی‌کنند و کلاس‌ها مرکز ثبات می‌مانند پس کلاسترینگ بصورت زیر خواهد بود:

$$C_1 = \{x_1, x_2, x_3\}$$

$$C_2 = \{x_4, x_5\}$$

$$\Rightarrow \mu_1 = \left[\frac{1}{2}, \frac{2}{3} \right]$$

$$\mu_2 = [5, 1]$$

✓

b)

$$\mu_i = \frac{1}{n_i} \sum_{x \in C_i} x_i \Rightarrow \mu_1 = \left[\frac{5}{3}, \frac{2}{3} \right] \quad \mu_2 = \left[\frac{13}{4}, 1 \right]$$

$$d = \|x - C_i\|_1$$

| | |
|----------------|----------------|
| $d_1 = 3$ ① | $d_1 = 4,25$ |
| $d_2 = 2,33$ ① | $d_2 = 4,25$ |
| $d_3 = 0,83$ ① | $d_3 = 2,75$ |
| $d_4 = 4$ | $d_4 = 2,75$ ② |
| $d_5 = 4,67$ | $d_5 = 2,75$ ② |

$$C_1 = \{x_1, x_2, x_3\} \quad C_2 = \{x_4, x_5\}$$

$$\Rightarrow \mu_1 = \left[\frac{1}{2}, \frac{2}{3} \right] \quad \mu_2 = [5, 1]$$

| | |
|----------------|-------------|
| $d_1 = 1,83$ ① | $d_1 = 6$ |
| $d_2 = 1,17$ ① | $d_2 = 6$ |
| $d_3 = 1,67$ ① | $d_3 = 4,5$ |
| $d_4 = 5,17$ | $d_4 = 1$ ② |
| $d_5 = 5,83$ | $d_5 = 1$ ② |

نتیجه به اینکه داده ها تغییر نمی کنند و کلاس و مراکز ثابت می ماند پس کلاسترینگ بصورت زیر خواهد بود


$$C_1 = \{x_1, x_2, x_3\} \quad C_2 = \{x_4, x_5\}$$

$$\Rightarrow \mu_1 = \left[\frac{1}{2}, \frac{2}{3} \right] \quad \mu_2 = [5, 1]$$

پاسخ ۶- شبیه سازی


۶-۱. قسمت ۱

مقدار مقادیر ویژه را برای ۳۰ تای اول بصورت زیر رسم میکنیم:



اکنون برای بدست آوردن مقدار بهینه برای تعداد component ها، باید میزان واریانس پوششی در تعداد انتخاب کامپوننت ها دخیل کنیم.


همانطور که میدانیم مقادیر ویژه درصدی از واریانس پوششی را نشان میدهند، به همین منظور ما به ترتیب بزرگی مقادیر ویژه از ابتدا دو به دو بصورت تجمیعی با هم جمع کرده و در انتها به مجموع همه مقادیر ویژه ها تقسیم میکنیم که درصد پوشش واریانس بر اساس تعداد انتخاب کامپوننت ها بدست آید که بصورت زیر قابل نمایش است:




ما در شکل بالا برای ۱۵۰۰ تای اول رسم کردیم که همانطور که مشخص است تا این حدود نیز کاملاً همپوشانی دارد. (تعداد کل مقادیر ویژه حدود ۲۵۰۰ میباشد)

۶-۲. قسمت ۲

پنج eigenface اول و آخر را بصورت زیر رسم میکنیم:



۵ تا از ۴۰۰ تا ۴۰۵ نیز رسم میکنیم:



همانطور که مشاهده میشود، با انتخاب eigenface متناسب با مقدار ویژه بالاتر، تصویر واضح تر بوده و ویژگی های بیشتری در آن پیداست.

در صورتی که هرچه مقدار ویژه کم میشود، تصویر ناواضح میشود و ویژگی خاصی در آن مشخص نیست.

۳-۶. قسمت ۳

نتیجه KNN قبل از اعمال PCA:

| | |
|-----------------------------|------------------------------|
| Results for k=1: | Results for k=2: |
| Accuracy (CCR): 37.37% | Accuracy (CCR): 32.88% |
| Confusion Matrix: | Confusion Matrix: |
| [[215 13 87 141 100 40 203] | [[275 17 119 203 90 28 67] |
| [9 32 6 12 6 6 16] | [13 34 8 15 6 4 7] |
| [78 12 297 124 118 68 123] | [140 21 320 158 100 42 39] |
| [131 31 101 586 181 54 359] | [273 59 188 650 133 41 99] |
| [100 16 100 203 298 46 203] | [189 39 167 261 224 23 63] |
| [36 8 38 93 41 336 82] | [84 18 87 150 63 214 18] |
| [97 18 78 228 135 55 382]] | [176 29 133 324 121 39 171]] |

نتیجه KNN بعد از اعمال PCA:

در این قسمت ما تعداد کامپوننت ها را برابر با ۴۰ میگیریم چون بیش از ۸۵ درصد از واریانس را پوشش


میدهد.

| | |
|-----------------------------|------------------------------|
| Results for k=1: | Results for k=2: |
| Accuracy (CCR): 38.12% | Accuracy (CCR): 32.72% |
| Confusion Matrix: | Confusion Matrix: |
| [[222 10 88 160 120 44 155] | [[301 14 127 199 80 35 43] |
| [8 34 6 18 4 5 12] | [18 35 12 14 4 2 2] |
| [82 14 319 132 108 79 86] | [163 18 348 148 76 44 23] |
| [177 22 118 617 169 66 274] | [317 50 211 629 126 44 66] |
| [111 15 108 235 288 50 159] | [218 24 155 296 205 31 37] |
| [44 7 49 91 42 351 50] | [97 15 114 130 50 219 9] |
| [118 16 89 228 121 63 358]] | [199 22 159 313 110 48 142]] |

درصد کمی بهبود داشتیم.

۴-۶. قسمت ۴

حال مقدار component ها را از ۱ تا ۱۵۰۰ به فاصله ۱۵ تغییر می‌دهیم و نمودار CCR طبقه بندی را به ازای مقادیر مختلف کامپوننت ها و الگوریتم KNN رسم می‌کنیم:



همانطور که مشاهده میشود با افزایش تعداد کامپوننت ها درصد خطا کاهش می یابد، که علت آن زیاد بودن تعداد ویژگی ها می باشد که overfit رخ میدهد.


بهترین CCR مربوط به $\text{component number} = 100$ میباشد که ۹۰ درصد واریانس را شامل میشود.

پاسخ ۷ - شبیه سازی

مقادیر خطا بصورت زیر میباشد:

```
[93.83229508196722,  
81.11734342160571,  
69.32670239596469,  
66.61060739806642,  
57.621179066834806,  
50.898548759983186,  
46.256575241698194,  
42.76497793190416,  
40.53441677175284,  
38.378726355611605,  
36.86745376208491,  
36.29489911727617,  
34.937999159310635,  
33.325853299705756,  
32.17346258932324,  
31.13505359394704,  
30.196784363177805,  
29.519056326187474,  
29.310569567044976,  
28.42510508617066,  
27.39145018915511,  
26.605081967213113,  
25.827607187894074,  
25.12198087431694,  
24.546709751996637,  
23.92194094157209,  
23.47336485918453,  
22.954584909625893,  
22.52255884825557,  
22.45190941572089]
```

با رسم مقادیر خطا داریم:



همانطور که مشاهده میشود، نقطه ای که شروع به کم شدن میکند را بعنوان نقطه بهینه انتخاب میکنیم، نحوه انتخاب به این صورت بوده است که یک $\text{threshold} = 1$ تعریف شده است و در صورتی که اختلاف با خطای قبلی کمتر از این مقدار باشد، این نقطه بعنوان زانو انتخاب میشود.

با قرار دادن $k = 12$ و فشرده کردن تصویر داریم:

Original Image



Compressed Image ($k=12$)

